Linux 下的DMA浅析



DMA是一种无需CPU的参与就可以让外设和系统内存之间进行双向数据传输的硬件机制。使用DMA可以使系统CPU从实际的I/O数据传输过程中摆脱出来,从而大大提高系统的吞吐率。DMA经常与硬件体系结构 特别是外设的总线技术密切相关。

一、DMA控制器硬件结构

DMA允许外围设备和主内存之间直接传输 I/O 数据, DMA 依赖于系统。每一种体系结构 DMA传输不同,编程接口也不同。数据传输可以以两种方式触发:一种**软件请求数据**,另一种**由硬件异步传输**。

a -- 软件请求数据

调用的步骤可以概括如下(以read为例):

- (1) 在进程调用 read 时,驱动程序的方法分配一个 DMA 缓冲区,随后指示硬件传送它的数据。进程进入睡眠。
- (2) 硬件将数据写入 DMA 缓冲区并在完成时产生一个中断。
- (3) 中断处理程序获得输入数据,应答中断,最后唤醒进程,该进程现在可以读取数据了。

b -- 由硬件异步传输

在 DMA 被异步使用时发生的。以数据采集设备为例:

- (1) 硬件发出中断来通知新的数据已经到达。
- (2) 中断处理程序分配一个DMA缓冲区。
- (3) 外围设备将数据写入缓冲区, 然后在完成时发出另一个中断。
- (4) 处理程序利用DMA分发新的数据,唤醒任何相关进程。

网卡传输也是如此,网卡有一个**循环缓冲区(通常叫做 DMA 环形缓冲区)**建立在与处理器共享的内存中。每一个输入数据包被放置在环形缓冲区中下一个可用缓冲区,并且发出中断。然后驱动程序将网络数据包传给内核的其它部分处理,并在环形缓冲区中放置一个新的 DMA 缓冲区。

驱动程序在初始化时分配DMA缓冲区,并使用它们直到停止运行。

二、DMA通道使用的地址

DMA通道用dma_chan结构数组表示,这个结构在kernel/dma.c中,列出如下:

```
struct dma_chan {
   int lock;
   const char *device_id;
};

static struct dma_chan dma_chan_busy[MAX_DMA_CHANNELS] = {
   [4] = { 1, "cascade" },
};
```

如果dma_chan_busy[n].lock != 0表示忙,DMA0保留为DRAM更新用,DMA4用作级联。DMA 缓冲区的主要问题是,当它大于一页时,它必须占据物理内存中的连续页。

由于DMA需要连续的内存,因而在引导时分配内存或者为缓冲区保留物理 RAM 的顶部。在引导时给内核传递一个"mem="参数可以保留 RAM 的顶部。例如,如果系统有 32MB 内存,参数"mem=31M"阻止内核使用最顶部的一兆字节。稍后,模块可以使用下面的代码来访问这些保留的内存:

dmabuf = ioremap(0x1F00000 /* 31M */, 0x100000 /* 1M */);

分配 DMA 空间的方法,代码调用 kmalloc(GFP_ATOMIC) 直到失败为止,然后它等待内核释放若干页面,接下来再一次进行分配。最终会发现由连续页面组成的DMA 缓冲区的出现。

一个使用 DMA 的设备驱动程序通常会与连接到接口总线上的硬件通讯,这些硬件使用物理地址,而程序代码使用虚拟地址。基于 DMA 的硬件使用总线地址而不是物理地址,有时,接口总线是通过将 I/O 地址映射到不同物理地址的桥接电路连接的。甚至某些系统有一个页面映射方案,能够使任意页面在外围总线上表现为连续的。

当驱动程序需要向一个 I/O 设备(例如扩展板或者DMA控制器)发送地址信息时,必须使用 virt_to_bus 转换,在接受到来自连接到总线上硬件的地址信息时,必须使用 bus_to_virt 了。

三、DMA操作函数

写一个DMA驱动的主要工作包括: DMA通道申请、DMA中断申请、控制寄存器设置、挂入DMA等待队列、清除DMA中断、释放 DMA通道

因为 DMA 控制器是一个系统级的资源,所以内核协助处理这一资源。内核使用 **DMA 注册表**为 DMA 通道提供了请求/释放机制,并且提供了一组函数在 DMA 控制器中配置通道信息。

以下具体分析关键函数 (linux/arch/arm/mach-s3c2410/dma.c)

```
int s3c2410_request_dma(const char *device_id, dmach_t channel,
   dma_callback_t write_cb, dma_callback_t read_cb) (s3c2410_dma_queue_buffer);
函数描述:申请某通道的DMA资源,填充s3c2410_dma_t 数据结构的内容,申请DMA中断。
输入参数: device id DMA 设备名: channel 通道号:
write_cb DMA 写操作完成的回调函数; read_cb DMA 读操作完成的回调函数
输出参数: 若channel 通道已使用,出错返回; 否则,返回0
int s3c2410_dma_queue_buffer(dmach_t channel, void *buf_id,
dma_addr_t data, int size, int write) (s3c2410_dma_stop);
函数描述:这是DMA操作最关键的函数,它完成了一系列动作:分配并初始化一个DMA内核缓冲区控制结构,并将它插入DMA等待队列,设置DMA控制寄存器内容,等
输入参数: channel 通道号; buf_id,缓冲区标识
dma_addr_t data DMA数据缓冲区起始物理地址; size DMA数据缓冲区大小; write 是写还是读操作
输出参数:操作成功,返回0;否则,返回错误号
int s3c2410 dma stop(dmach t channel)
//函数描述:停止DMA操作。
int s3c2410_dma_flush_all(dmach_t channel)
//函数描述: 释放DMA通道所申请的所有内存资源
void s3c2410_free_dma(dmach_t channel)
//函数描述:释放DMA通道
```

四、DMA映射

一个DMA映射就是分配一个 DMA 缓冲区并为该缓冲区生成一个能够被设备访问的地址的组合操作。一般情况下,简单地调用函数virt_to_bus 就设备总线上的地址,但有些硬件映射寄存器也被设置在总线硬件中。映射寄存器(mapping register)是一个类似于外围设备的虚拟内存等价物。在使用这些寄存器的系统上,外围设备有一个相对较小的、专用的地址区段,可以在此区段执行 DMA。通过映射寄存器,这些地址被重映射到系统 RAM。映射寄存器具有一些好的特性,包括使分散的页面在设备地址空间看起来是连续的。但不是所有的体系结构都有映射寄存器,特别地,PC 平台没有映射寄存器。

在某些情况下,为设备设置有用的地址也意味着需要构造一个反弹(bounce)缓冲区。例如,当驱动程序试图在一个不能被外围设备访问的地址(一个高端内存地址)上执行 DMA 时,反弹缓冲区被创建。然后,按照需要,数据被复制到反弹缓冲区,或者从反弹缓冲区复制。

根据 DMA 缓冲区期望保留的时间长短, PCI 代码区分两种类型的 DMA 映射:

a -- 一致 DMA 映射

它们存在于驱动程序的生命周期内。一个被一致映射的缓冲区必须同时可被 CPU 和外围设备访问,这个缓冲区被处理器写时,可立即被设备读取而没有cache效应,反之亦然,使用函数pci_alloc_consistent建立一致映射。

b -- 流式 DMA映射

流式DMA映射是为单个操作进行的设置。它映射处理器虚拟空间的一块地址,以致它能被设备访问。应尽可能使用流式映射,而不是一致映射。这是因为在支持一致映射的系统上,每个 DMA 映射会使用总线上一个或多个映射寄存器。具有较长生命周期的一致映射,会独占这些寄存器很长时间——即使它们没有被使用。使用函数dma_map_single建立流式映射。

1、建立一致 DMA 映射

函数pci_alloc_consistent处理缓冲区的分配和映射,函数分析如下(在include/asm-generic/pci-dma-compat.h中):

结构**dma_coherent_mem**定义了DMA一致性映射的内存的地址、大小和标识等。结构dma_coherent_mem列出如下(在 arch/i386/kernel/pci-dma.c中):

```
struct dma_coherent_mem {
   void     *virt_base;
   u32     device_base;
   int     size;
   int     flags;
   unsigned long *bitmap;
};
```

函数**dma_alloc_coherent**分配size字节的区域的一致内存,得到的dma_handle是指向分配的区域的地址指针,这个地址作为区域的物理基地址。dma_handle是与总线一样的位宽的无符号整数。 函数dma_alloc_coherent分析如下(在arch/i386/kernel/pci-dma.c中):

```
void *dma_alloc_coherent(struct device *dev, size_t size,
             dma_addr_t *dma_handle, int gfp)
{
   void *ret:
   //若是设备,得到设备的dma内存区域,即mem= dev->dma_mem
   struct dma_coherent_mem *mem = dev ? dev->dma_mem : NULL;
   int order = get_order(size);//将size转换成order,即
   //忽略特定的区域, 因而忽略这两个标识
   gfp &= ~(__GFP_DMA | __GFP_HIGHMEM);
   if (mem) {//设备的DMA映射, mem= dev->dma_mem
      //找到mem对应的页
       int page = bitmap_find_free_region(mem->bitmap, mem->size,
                           order);
       if (page >= 0) {
           *dma_handle = mem->device_base + (page << PAGE_SHIFT);
           ret = mem->virt_base + (page << PAGE_SHIFT);</pre>
           memset(ret, 0, size);
           return ret;
       }
       if (mem->flags & DMA_MEMORY_EXCLUSIVE)
           return NULL;
   //不是设备的DMA映射
   if (dev == NULL || (dev->coherent_dma_mask < 0xffffffff))</pre>
       gfp |= GFP_DMA;
   //分配空闲页
```

当不再需要缓冲区时(通常在模块卸载时),应该调用函数 pci_free_consitent 将它返还给系统。

2、建立流式 DMA 映射

在流式 DMA 映射的操作中,缓冲区传送方向应匹配于映射时给定的方向值。缓冲区被映射后,它就属于设备而不再属于处理器了。在缓冲区调用函数pci_unmap_single撤销映射之前,驱动程序不应该触及其内容。

在缓冲区为 DMA 映射时,内核必须确保缓冲区中所有的数据已经被实际写到内存。可能有些数据还会保留在处理器的高速缓冲存储器中,因此必须显式刷新。在刷新之后,由处理器写入缓冲区的数据对设备来说也许是不可见的。

如果欲映射的缓冲区位于设备不能访问的内存区段时,某些体系结构仅仅会操作失败,而其它的体系结构会创建一个反弹缓冲区。反弹缓冲区是被设备访问的独立内存区域,反弹缓冲区复制原始缓冲区的内容。

函数**pci_map_single**映射单个用于传送的缓冲区,返回值是可以传递给设备的总线地址,如果出错的话就为 NULL。一旦传送完成,应该使用函数pci_unmap_single 删除映射。其中,参数direction为传输的方向,取值如下:

```
PCI DMA TODEVICE 数据被发送到设备。
```

PCI DMA FROMDEVICE如果数据将发送到 CPU。

PCI_DMA_BIDIRECTIONAL数据进行两个方向的移动。

PCI_DMA_NONE 这个符号只是为帮助调试而提供。

函数pci_map_single分析如下(在arch/i386/kernel/pci-dma.c中)

函数**dma_map_single**映射一块处理器虚拟内存,这块虚拟内存能被设备访问,返回内存的物理地址,函数dma_map_single分析如下(在include/asm-i386/dma-mapping.h中):

```
static inline dma_addr_t dma_map_single(struct device *dev, void *ptr, size_t size, enum dma_data_direction direction)

{

BUG_ON(direction == DMA_NONE);

//可能有些数据还会保留在处理器的高速缓冲存储器中,因此必须显式刷新
flush_write_buffers();

return virt_to_phys(ptr); //虚拟地址转化为物理地址

}
```

3、分散/集中映射

分散/集中映射是流式 DMA 映射的一个特例。它将几个缓冲区集中到一起进行一次映射,并在一个 DMA 操作中传送所有数据。这些分散的缓冲区由分散表结构scatterlist来描述,多个分散的缓冲区的分散表结构组成缓冲区的struct scatterlist数组。

分散表结构列出如下(在include/asm-i386/scatterlist.h):

```
struct scatterlist {
    struct page    *page;
```

```
unsigned int offset; | dma_addr_t dma_address; //用在分散/集中操作中的缓冲区地址 unsigned int length;//该缓冲区的长度 };
```

每一个缓冲区的地址和长度会被存储在 struct scatterlist 项中,但在不同的体系结构中它们在结构中的位置是不同的。下面的两个宏定义来解决平台移植性问题,这些宏定义应该在一个pci_map_sg 被调用后使用:

```
//从该分散表项中返回总线地址
#define sg_dma_address(sg) �sg)->dma_address)
//返回该缓冲区的长度
#define sg_dma_len(sg) �sg)->length)
```

函数 pci_map_sg完成分散/集中映射,其返回值是要传送的 DMA 缓冲区数;它可能会小于 nents(也就是传入的分散表项的数量),因为可能有的缓冲区地址上是相邻的。一旦传输完成,分散/集中映射通过调用函数pci_unmap_sg 来撤销映射。 函数pci_map_sg分析如下(在include/asm-generic/pci-dma-compat.h中):

```
static inline int pci_map_sg(struct pci_dev *hwdev, struct scatterlist *sg,
                             int nents, int direction)
{
   return dma_map_sg(hwdev == NULL ? NULL : &hwdev->dev, sg, nents,
(enum dma_data_direction);
include/asm-i386/dma-mapping.h
static inline int dma_map_sg(struct device *dev, struct scatterlist *sg,
int nents, enum dma data direction direction)
{
   int i;
   BUG ON(direction == DMA NONE);
   for (i = 0; i < nents; i++) {
       BUG_ON(!sg[i].page);
      //将页及页偏移地址转化为物理地址
       sg[i].dma_address = page_to_phys(sg[i].page) + sg[i].offset;
   //可能有些数据还会保留在处理器的高速缓冲存储器中,因此必须显式刷新
   flush_write_buffers();
   return nents:
}
```

五、DMA池

许多驱动程序需要又多又小的一致映射内存区域给DMA描述子或I/O缓存buffer,这使用DMA池比用dma_alloc_coherent分配的一页或多页内存区域好,DMA池用函数dma_pool_create创建,用函数dma_pool_alloc从DMA池中分配一块一致内存,用函数dmp_pool_free放内存回到DMA池中,使用函数dma_pool_destory释放DMA池的资源。

结构dma_pool是DMA池描述结构,列出如下:

```
struct dma_pool { /* the pool */
  struct list_head page_list;//页链表
   spinlock_t
              lock;
           blocks_per_page; //每页的块数
  size_t
  size_t
              size; //DMA池里的一致内存块的大小
  struct device
                  *dev; // 将做DMA 的设备
              allocation; //分配的没有跨越边界的块数,是size的整数倍
               name [32]; //池的名字
   wait_queue_head_t waitq; //等待队列
   struct list head
                  pools;
};
```

函数**dma_pool_create**给DMA创建一个一致内存块池,其参数name是DMA池的名字,用于诊断用,参数dev是将做DMA的设备,参数size是DMA池里的块的大小,参数align是块的对齐要求,是2的幂,参数allocation返回没有跨越边界的块数(或0)。

函数dma_pool_create返回创建的带有要求字符串的DMA池,若创建失败返回null。对被给的DMA池,函数dma_pool_alloc被用来分配内存,这些内存都是一致DMA映射,可被设备访问,且没有使用缓存刷新机制,因为对齐原因,分配的块的实际尺寸比请求的大。如果分配非0的内存,从函数dma_pool_alloc返回的对象将不跨越size边界(如不跨越4K字节边界)。这对在个体的DMA传输上有地址限制的设备来说是有利的。

函数dma pool create分析如下(在drivers/base/dmapool.c中):

```
struct dma_pool *dma_pool_create (const char *name, struct device *dev,
                    size_t size, size_t align, size_t allocation)
   struct dma_pool
                      *retval;
   if (align == 0)
       align = 1:
   if (size == 0)
       return NULL;
   else if (size < align)
       size = align;
   else if ((size % align) != 0) {//对齐处理
       size += align + 1;
       size &= ~(align - 1);
   //如果一致内存块比页大,是分配为一致内存块大小,否则,分配为页大小
   if (allocation == 0) {
       if (PAGE_SIZE < size)//页比一致内存块小
          allocation = size;
           allocation = PAGE_SIZE;//页大小
       // FIXME: round up for less fragmentation
   } else if (allocation < size)
       return NULL;
   //分配dma_pool结构对象空间
   if (!(retval = kmalloc (sizeof *retval, SLAB_KERNEL)))
       return retval;
   strlcpy (retval->name, name, sizeof retval->name);
   retval->dev = dev;
   //初始化dma pool结构对象retval
   INIT_LIST_HEAD (&retval->page_list);//初始化页链表
   spin_lock_init (&retval->lock);
   retval->size = size;
   retval->allocation = allocation;
   retval->blocks_per_page = allocation / size;
   init waitqueue head (&retval->waitq);//初始化等待队列
   if (dev) {//设备存在时
       down (&pools_lock);
       if (list_empty (&dev->dma_pools))
          //给设备创建sysfs文件系统属性文件
           device_create_file (dev, &dev_attr_pools);
       /* note: not currently insisting "name" be unique */
       list_add (&retval->pools, &dev->dma_pools); //将DMA池加到dev中
       up (&pools_lock);
       INIT LIST HEAD (&retval->pools);
   return retval;
```

函数dma_pool_alloc从DMA池中分配一块一致内存,其参数pool是将产生块的DMA池,参数mem_flags是GFP_*位掩码,参数handle是指向块的DMA地址,函数dma_pool_alloc返回当前没用的块的内核虚拟地址,并通过handle给出它的DMA地址,如果内存块不能被分配,返回null。

函数dma_pool_alloc包裹了dma_alloc_coherent页分配器,这样小块更容易被总线的主控制器使用。这可能共享slab分配器的内容。

函数dma_pool_alloc分析如下(在drivers/base/dmapool.c中):

```
void *dma pool alloc (struct dma pool *pool, int mem flags, dma addr t *handle)
{
   unsigned long
                      flags;
   struct dma_page
                      *page;
   int
            map, block;
   size_t
                offset;
   void
                 *retval;
restart:
   spin_lock_irqsave (&pool->lock, flags);
   list_for_each_entry(page, &pool->page_list, page_list) {
      int
            i:
       /* only cachable accesses here ... */
       //遍历一页的每块,而每块又以32字节递增
       for (map = 0, i = 0);
              i < pool->blocks_per_page; //每页的块数
               i += BITS_PER_LONG, map++) { // BITS_PER_LONG定义为32
           if (page->bitmap [map] == 0)
              continue;
           block = ffz (~ page->bitmap [map]);//找出第一个0
           if ((i + block) < pool->blocks_per_page) {
               clear_bit (block, &page->bitmap [map]);
           //得到相对于页边界的偏移
              offset = (BITS_PER_LONG * map) + block;
              offset *= pool->size;
              goto ready;
           }
   }
//给DMA池分配dma_page结构空间,加入到pool->page_list链表,
//并作DMA一致映射,它包括分配给DMA池一页。
// SLAB_ATOMIC表示调用 kmalloc(GFP_ATOMIC) 直到失败为止,
//然后它等待内核释放若干页面,接下来再一次进行分配。
   if (!(page = pool_alloc_page (pool, SLAB_ATOMIC))) {
       if (mem_flags & __GFP_WAIT) {
           DECLARE_WAITQUEUE (wait, current);
           current->state = TASK_INTERRUPTIBLE;
           add wait queue (&pool->waitq, &wait);
           spin unlock irgrestore (&pool->lock, flags);
           schedule_timeout (POOL_TIMEOUT_JIFFIES);
           remove_wait_queue (&pool->waitq, &wait);
           goto restart;
       }
       retval = NULL;
       goto done;
   }
   clear_bit (0, &page->bitmap [0]);
   offset = 0;
readv:
   page->in use++;
   retval = offset + page->vaddr; //返回虚拟地址
    *handle = offset + page->dma; //相对DMA地址
#ifdef CONFIG_DEBUG_SLAB
   memset (retval, POOL_POISON_ALLOCATED, pool->size);
#endif
   spin_unlock_irqrestore (&pool->lock, flags);
   return retval:
}
```

六、一个简单的使用DMA 例子

示例:下面是一个简单的使用DMA进行传输的驱动程序,它是一个假想的设备,只列出DMA相关的部分来说明驱动程序中如何使用DMA的。

函数dad_transfer是设置DMA对内存buffer的传输操作函数,它使用流式映射将buffer的虚拟地址转换到物理地址,设置好DMA控制器,然后开始传输数据。

```
int dad_transfer(struct dad_dev *dev, int write, void *buffer,
                  size_t count)
       dma_addr_t bus_addr;
       unsigned long flags;
       /* Map the buffer for DMA */
       dev->dma_dir = (write ? PCI_DMA_TODEVICE : PCI_DMA_FROMDEVICE);
       dev->dma size = count;
       //流式映射,将buffer的虚拟地址转化成物理地址
       bus_addr = pci_map_single(dev->pci_dev, buffer, count,
                              dev->dma_dir);
       dev->dma_addr = bus_addr; //DMA传送的buffer物理地址
       //将操作控制写入到DMA控制器寄存器,从而建立起设备
       writeb(dev->registers.command, DAD_CMD_DISABLEDMA);
      //设置传输方向--读还是写
       writeb(dev->registers.command, write ? DAD_CMD_WR : DAD_CMD_RD);
       writel(dev->registers.addr, cpu_to_le32(bus_addr));//buffer物理地址
       writel(dev->registers.len, cpu_to_le32(count)); //传输的字节数
       //开始激活DMA进行数据传输操作
       writeb(dev->registers.command, DAD CMD ENABLEDMA);
       return 0;
    }
4
```

函数dad_interrupt是中断处理函数,当DMA传输完时,调用这个中断函数来取消buffer上的DMA映射,从而让内核程序可以访问这个buffer。

函数dad open打开设备,此时应申请中断号及DMA通道

| }

在与open 相对应的 close 函数中应该释放DMA及中断号。

函数dad dma prepare初始化DMA控制器,设置DMA控制器的寄存器的值,为 DMA 传输作准备。

函数dad_dma_isdone用来检查 DMA 传输是否成功结束。

```
int dad_dma_isdone(int channel)
{
   int residue;
   unsigned long flags = claim_dma_lock ();
   residue = get_dma_residue(channel);
   release_dma_lock(flags);
   return (residue == 0);
}
```